

**UNIVERSITÀ
DEGLI STUDI
DI PADOVA**

Studio e approfondimento di metodi e procedure innovative per il
deep learning mediante integrazione tra dati ottici, termici e
point-cloud

Mer Mec Engineering Srl

Università degli Studi di Padova - Prof. Francesco Pirotti

2024-10-01

INDICE

1	Acronimi	1
2	Introduzione	1
3	Definizione del problema	1
4	Materiali e metodi	3
4.1	Materiali	3
4.1.1	Raster GeoTIFF	3
4.1.2	Nuvole di punti LAS/LAZ	3
4.2	Metodi	3
4.2.1	Pre-elaborazione	4
4.2.1.1	Verifica degli elementi dell'infrastruttura	4
4.2.1.2	Verifica del sistema di riferimento	5
4.2.1.3	Verifica della nuvola di punti	6
4.2.2	Elaborazione	6
4.2.2.1	Approccio AI / Deeplearning	6
4.2.2.2	Caratteristiche geometriche 3D	7
5	Risultati	9
6	Schemi progettuali dell'applicativo software	9
6.1	Premessa	9
6.2	Interfaccia	10
6.3	Architettura	11
6.4	Addestramento e validazione	11
7	Proposte migliorative	14
8	Riferimenti	14

Indice delle figure

1	Peso in funzione dell'altezza di una latifolia generica in un buon contesto di fertilità. . .	2
2	Risultati della verifica del file LAS	4
3	Presenza coordinata Z nel vettoriale dell'infrastruttura	5
4	Valori di Eigen della matrice di covarianza delle coordinate prese in un raggio idoneo (fonte immagine: Hansen et al. (2021) e Qin et al. (2018)).	8
5	Componenti dello schema modulare di processo	10
6	Diagramma di flusso dell'applicativo software di deep learning integrato.	12
7	Schema progettuale generale dell'applicativo software di deep learning integrato.	13

1 Acronimi

Vengono utilizzati nel testo le seguenti abbreviazioni/acronimi.

- **GSD - ground sampling distance** - distanza tra un centro della cella in un raster e quello prossimo più vicino - equivale alla misura del lato della cella e solitamente è uguale nelle due direzioni, tra colonne e tra righe della matrice raster
- **NdP - nuvola di punti** / point-cloud in inglese: prodotto di un rilievo con scanner laser o con tecniche fotogrammetriche che restituiscono coordinate 3D, quindi punti, nello spazio distribuiti in modo irregolare.
- **DL/ML - deep learning / machine learning** - due categorie di algoritmi di intelligenza artificiale utilizzati per creare modelli addestrati con approcci differenti. Entrambe le categorie racchiudono un ampio spettro di metodi differenti. Il **deep learning** è una categoria specifica di machine learning dove vengono utilizzate reti neurali artificiali che consentono di imparare a riconoscere schemi non facilmente identificabili dai dati forniti.
- **HPC - High Performance Computing** - infrastruttura di calcolo con alta capacità di elaborazione dati grazie a diverse strategie (e.g. molteplici processori per il calcolo parallelo e/o molteplici GPU dedicate alle procedure di AI). Da notare che la necessità di disponibilità dei diversi elementi di calcolo dipende dalla specifica esigenza di ogni fase di calcolo. In altre parole se il calcolo non è parallelizzabile, non verrà sfruttato più di un core/CPU.
- **SR** - Sistema di Riferimento delle coordinate. Sistema di riferimento cartografico o geografico al quale fanno riferimento le coordinate dei dati spaziale.

2 Introduzione

Questo documento presenta una sintesi delle funzionalità e specifiche tecniche di un applicativo software sviluppato per il monitoraggio dell'infrastruttura ferroviaria utilizzando tecniche di deep learning. L'applicativo integra dati da sensori ottici, termici e LiDAR (nuvole di punti) per identificare e mitigare i rischi associati alla vegetazione circostante. L'obiettivo principale è prevenire potenziali danni causati dalla vegetazione e migliorare la sicurezza dell'infrastruttura.

3 Definizione del problema

In questo progetto, il problema affrontato è il monitoraggio del rischio rappresentato dalla vegetazione adiacente alla rete ferroviaria. L'obiettivo è prevenire danni fisici, come la caduta di alberi o rami, mediante un sistema automatizzato che utilizza tecniche avanzate di deep learning per analizzare dati telerilevati e generare una mappa di rischio aggiornata. La valutazione si basa su parametri geospaziali e ambientali che includono altezza, distanza dalla ferrovia e condizioni di salute della vegetazione.

Nello specifico, Mer Mec Engineering Srl utilizza dati telerilevati da diverse piattaforme e sensori per monitorare lo stato dell'infrastruttura ferroviaria, inclusi gli elementi ad essa vicini che possono essere fonti di disturbo e di potenziale pericolo per elementi dell'infrastruttura o parti di essa. L'area immediatamente limitrofa è dunque da attenzionare, e risulta utile identificare preventivamente gli elementi di rischio presenti. In particolare la vegetazione gioca un ruolo importante: mentre apporta un indubbio consolidando del terreno, porta anche un aumento della probabilità di danno da caduta di intere piante, o parte di esse. E' utile riportare sotto l'equazione di Chave et al. (2014) ed un grafico che riporta il peso di una latifoglia su terreno mediamente fertile, dal quale si evince un peso importante una volta raggiunta la maturità.

$$AGB_tree = 0.0673 \times (WD \times H \times DBH^2)^{0.976}$$

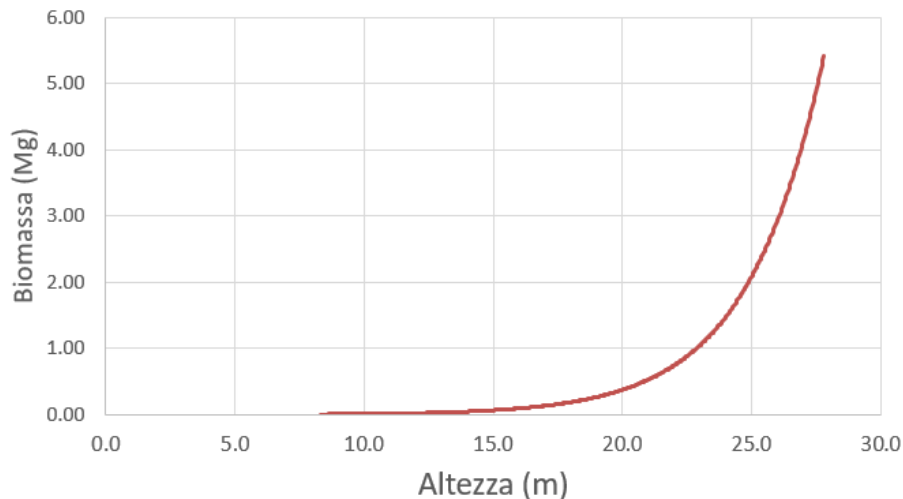


Fig. 1: Peso in funzione dell'altezza di una latifoglia generica in un buon contesto di fertilità.

Non solo il peso ma l'ingombro di materiale non prettamente cormometrico sopra le rotaie è da prendere in considerazione, come anche rischi derivati come incendio.

Riuscire a quantificare il rischio ed associarlo alle aree di interesse e, dove possibile, al singolo elemento della vegetazione, è l'obiettivo generale del lavoro. Per perseguire questo, nel documento si propone e si dettaglia l'integrazione di metodi di intelligenza artificiale (deep learning e machine learning) con procedimenti allo stato dell'arte per l'identificazione e quantificazione della vegetazione.

Come riferimento iniziale è stato utilizzata la relazione tecnica PROGETTO DI RICERCA MONDOROTAIA - RELAZIONE TECNICA "INTERFERENZA DELLA VEGETAZIONE SULL'INFRASTRUTTURA FERROVIARIA" (MERMEC - Autori Vari 2023).

In questo lavoro proponiamo l'approfondimento di metodi innovativi di deep learning per la valutazione del rischio di danneggiamento dell'infrastruttura ferroviaria causato da vegetazione. Integriamo dati ottici, termici e point cloud per creare mappe di rischio accurate.

Questa è una prima parte di un lavoro che si inserisce in un più ampio campo relativo all'utilizzazione della cosiddetta "intelligenza artificiale" per supportare la creazione di una mappa di rischio di danneggiamento dell'infrastruttura ferroviaria da parte di eventi calamitosi, usando dati telerilevati da fonti diverse in una infrastruttura comune di calcolo. In una seconda parte, quanto riportato verrà poi concretizzato in una pipeline di lavoro in ambiente R con un'interfaccia grafica che accompagni l'utilizzatore nel processo.

Nel contesto delle infrastrutture autostradali e ferroviarie, il rischio si riferisce alla possibilità di eventi che potrebbero avere un impatto negativo sulla sicurezza e sulla funzionalità con conseguenti costi economici.

Il rischio unisce sia la probabilità che un evento si verifichi (ad esempio, lo sradicamento di un albero a causa della vecchiaia o di patologie, oppure la rottura di un ramo di dimensioni importanti), sia la gravità delle conseguenze (ad esempio quantificando danni alle proprietà). In questo lavoro si identifica la prima componente del rischio.

Il rischio legato all'infrastruttura ferroviaria a causa della vegetazione si riferisce al potenziale danno causato dall'interazione diretta o indiretta tra essa ed elementi dell'infrastruttura. Ciò può comportare interruzioni delle operazioni ferroviarie, danni ai binari e all'infrastruttura e rischi per la sicurezza.

La vegetazione cresciuta eccessivamente può, in alcuni casi, aumentare il rischio di danno in quanto aumenta la probabilità che un evento porti alla rottura di rami, sradicamento, o anche inizio di incendi che hanno poi un effetto diretto o indiretto sull'infrastruttura ferroviaria.

Si fa notare inoltre che la recente letteratura scientifica dà evidenza di un aumento delle probabilità di eventi climatici più estremi rispetto alla media passata. Questo supporta l'ipotesi che ci saranno effetti importanti da monitorare, ed una mappatura dei differenti gradi di rischio è di notevole interesse.

4 Materiali e metodi

4.1 Materiali

Sono stati forniti file in formato raster GeoTIFF ed in formato nuvole di punti LAS e LAZ. Questi sono i formati più comunemente utilizzati e sono ottimizzati ed ottimizzabili per massimizzare l'efficienza di calcolo, mediante utilizzo di indici spaziali ed altri metodi per velocizzare le letture ed elaborazioni dei dati.

4.1.1 Raster GeoTIFF

I raster GeoTIFF consistono in griglie regolari a diverso GSD, in un sistema di riferimento definito internamente al file. I raster riportano valori utili alla classificazione tramite DL.

4.1.2 Nuvole di punti LAS/LAZ

E' stato fornito un file in formato LAS compresso (LAZ) versione 1.4 formato 7 con le seguenti caratteristiche:

area coperta: 78084 m²
no. punti: 828.600
densità media: 10.61 ritorni/m²
densità impulsi: 7.05 impulsi/m²

Una verifica della conformità ha dato risultati positivi con osservazioni di minore importanza, quali un numero di punti duplicati (con esatta identica coordinata XYZ). Errori facilmente risolvibili in modo automatico. Per quanto una questione di minore importanza, i punti identici possono inficiare eventuali calcoli relativi alle descrizioni delle geometrie degli elementi (geometric features).

4.2 Metodi

La procedura proposta si divide in due fasi. Una di pre-elaborazione ed una di elaborazione vera e propria. Entrambe le fasi faranno poi parte della "pipeline di lavoro" che verrà concretizzata nella seconda parte del lavoro mediante routine in ambiente R.

```

Checking the data
- Checking coordinates... ✓
- Checking coordinates type... ✓
- Checking coordinates range... ✓
- Checking coordinates quantization... ✓
- Checking attributes type... ✓
- Checking ReturnNumber validity... ✓
- Checking NumberOfReturns validity... ✓
- Checking ReturnNumber vs. NumberOfReturns... ✓
- Checking RGB validity... ✓
- Checking absence of NAs... ✓
- Checking duplicated points...
  ▲ 11824 points are duplicated and share XYZ coordinates with other points
- Checking degenerated ground points...
  ▲ There were 25 degenerated ground points. Some X Y coordinates were repeated but with different Z coordinates
- Checking attribute population...
  ⚠ 'EdgeOfFlightline' attribute is not populated
- Checking gpstime incoherences ✓
- Checking flag attributes... ✓
- Checking user data attribute... ✓
Checking the header
- Checking header completeness... ✓
- Checking scale factor validity... ✓
- Checking point data format ID validity... ✓
- Checking extra bytes attributes validity... ✓
- Checking the bounding box validity... ✓
- Checking coordinate reference system... ✓

```

Fig. 2: Risultati della verifica del file LAS

4.2.1 Pre-elaborazione

La fase di pre-elaborazione è dedicata alla verifica dell'esistenza delle informazioni necessarie per procedere con le successive analisi, ovvero la presenza di dati geo-referenziati, in un sistema di riferimento omogeneo, o, quantomeno, dovessero essere presenti sistemi di riferimento differenti, in questa fase viene verificata la possibilità di adottarne uno specifico ed eseguire le necessarie trasformazioni monitorando la tolleranza necessaria.¹

4.2.1.1 Verifica degli elementi dell'infrastruttura Il primo passo di questa fase richiede di identificare, mediante un file vettoriale correttamente geo-referenziato, gli oggetti per i quali identificare e quantificare fattori di rischio. Nel caso studio in questione trattasi della infrastruttura ferroviaria,.

Per prima cosa dunque è stata identificata la posizione nello spazio dell'infrastruttura ferroviaria. Il concetto di rischio infatti deve necessariamente inquadrare l'oggetto per il quale lo si vuole identificare. Per le caratteristiche di linearità dell'infrastruttura ferroviaria, è stato utilizzato un elemento vettoriale lineare preso dal geodatabase aperto Open Street Map (OSM).

NOTA: è ovviamente possibile utilizzare qualsiasi elemento vettoriale che rappresenta al meglio gli elementi intorno ai quali identificare il rischio da vegetazione, inclusi elementi vettoriali di tipo punto o poligono.

Questa viene identificata con un tratto lineare nell'area di test. Il tratto è stato ottenuto da Open-Streetmap, e sembra essere correttamente georiferito, se sovrapposto all'ortofoto fornita. Rimane però un elemento bidimensionale, si è dunque proceduto ad assegnare ai vertici un valore di quota utilizzando il modello digitale del terreno (DTM) fornito. Ad ogni modo anche se non fosse presente il DTM, questo è facilmente ottenibile dalla nuvola di punti correttamente classificata.

E' importante notare che il tracciato dell'infrastruttura, in questo caso elemento lineare, deve essere in 3d, ovvero avere i nodi con la coordinata Z corrispondente alla quota nello stesso sistema di riferimento del dato LAS/LAZ. In altre parole ci si deve assicurare che l'informazione sia correttamente georiferita anche nella sua terza dimensione, in modo da poter posizionare correttamente la linea dell'infrastruttura nel contesto 3D del modello. Nel caso questo non sia disponibile, è possibile utilizzare la nuvola di punti 3D per ricavare la posizione del tracciato, che è ragionevole pensare si collochi sul terreno, e dunque è possibile assegnare la coordinata Z ai nodi usando un modello 3D del terreno.

¹Si fa notare che la trasformazione alcuni datum cartografici può comportare un errori di diversi metri se non appongono le necessarie correzioni. Livelli informativi in sistemi di riferimento cartografici differenti vanno dunque trasformati in un sistema comune facendo attenzione ad eventuali limiti di tolleranza che sono funzione della scala di lavoro.

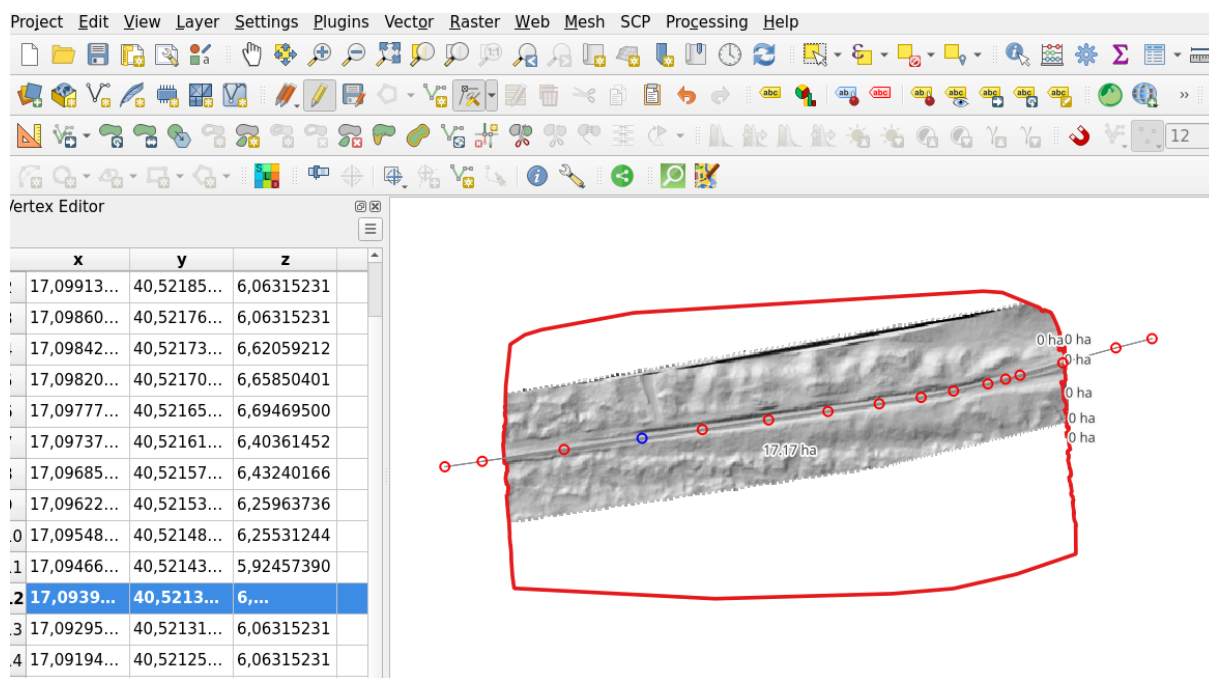



Fig. 3: Presenza coordinata Z nel vettoriale dell'infrastruttura

La scala ed accuratezza di questi elementi è stata verificata e ritenuta idonea. La verifica è avvenuta mediante sovrapposizione sull'ortofoto e sulle immagini NDVI e termica che hanno un passo di GSD=10 cm come in figura sotto.



Non è possibile una verifica statistica di una distribuzione di differenze rispetto alla posizione reale, ma se si presuppone che, dato il GSD, le ortoimmagini abbiano le caratteristiche di accuratezza corrispettive ad una scala 1:1000 . La differenza della posizione tra il tracciato e la stessa identificabile nell'ortofoto è certamente minore di 2 m. Si può dunque concludere che il posizionamento dell'infrastruttura soddisfi una tolleranza compatibile con una scala di 1:10000 o maggiore.

Per un utilizzo scalato ad aree più ampie si consiglia di verificare che tutti gli elementi rispettino un determinato grado di tolleranza in ambito planimetrico.

4.2.1.2 Verifica del sistema di riferimento Il sistema di riferimento di tutti i dati forniti è il RDN2008 / Italy Zone (E-N) ovvero la Rete Dinamica Nazionale su Frame ETRF2000 – 2008.0, del

sistema di riferimento geodetico europeo ETRS89.

La traccia dell'infrastruttura ferroviaria è stata presa da OSM; questi dati sono nel sistema di riferimento geografico WGS84 (Datum globale WGS84 EPSG:4326).

Come accennato all'inizio di quest sezione (Pre-elaborazione), in caso di sistemi di riferimento multipli, va creato un processo per armonizzare i sistemi ad uno unico. In questo caso è stato semplicemente trasformato il SR del tracciato dell'infrastruttura in quello del resto dei dati.

4.2.1.3 Verifica della nuvola di punti La nuvola di punti fornita è già classificata, condizione necessaria per le operazioni successive. Sono infatti necessarie le classi dalla 2 alla 6 inclusa. Per informazioni sulle classi vedi (Photogrammetry & Remote Sensing 2019).

La classe 2 è fondamentale in quanto identifica i punti al suolo e dunque consente tutte le operazioni successive, che consistono in una prima identificazione della vegetazione e delle chiome.

Nel caso non sia disponibile la nuvola di punti classificata, è necessario eseguire una procedura di classificazione assicurandosi una accuratezza minima nell'identificazione dei punti "terreno", i.e. classe 2. Questa procedura è ben nota in letteratura e può essere aggiunta al processo in caso sia necessario. Ad ogni modo solitamente i prodotti da rilievo LiDAR sono nuvole di punti già classificate.

Si presume dunque di avere come dato di partenza una nuvola di punti classificata con buona accuratezza.

4.2.2 Elaborazione

Stimare un valore di rischio associato alla vegetazione per un'infrastruttura è un problema complesso. Tronchi/rami più grandi rappresentano una minaccia maggiore, dunque va considerata la dimensione dell'albero. La distanza dall'infrastruttura, ovvero più vicina è la pianta, ed eventuali pendenze del suolo aumentano le probabilità di impattare componenti dell'infrastruttura. La salute dell'albero inoltre incide, dato che malattie, marciumi radicali e/o del tronco influenzano sulla probabilità di rottura di parti delle piante.

Le condizioni meteorologiche sono fattori con-causanti, ma non vengono qui prese in considerazione in quanto l'obiettivo del presente studio è quello di identificare le aree dove elementi della vegetazione possono essere considerati potenziali fattori di pericolo per l'infrastruttura.

4.2.2.1 Approccio AI / Deeplearning In questo contesto si definisce intelligenza artificiale / artificial intelligence (AI) come il termine generico che definisce un insieme di algoritmi sviluppati in un'informatica che simulare il modo di lavorare dell'apprendimento umano, tramite esempi e addestramento a riconoscere oggetti e contesti. L'AI può essere suddivisa in machine learning (ML) ovvero algoritmi che permettono ai sistemi di apprendere da dati e migliorare le proprie prestazioni nel tempo e deep learning (DL) che è un sottoinsieme del machine learning che utilizza reti neurali artificiali per apprendere da dati complessi, come immagini e, come in questo caso, nuvole di punti. Il deep learning sfrutta anche il contesto geospaziale per arricchire la descrizione del singolo elemento che deve essere assegnato ad una categoria (per operazioni di classificazione) oppure ad una quantità (per operazioni di regressione). Negli ultimi anni la letteratura scientifica si è arricchita di un numero molto elevato di approcci, alcuni dei quali dedicati alle nuvole di punti 3D (Qi et al. 2017)

In questo contesto le nuvole di punti sono state arricchite con "descrittori" aggiuntivi, necessari a descrivere la categoria da identificare mediante la procedura di AI. Diverse tipologie di descrittori sono stati utilizzati, e vengono sotto descritte.

Una prima categoria di descrittori è stata raccolta dai dati raster ottenuti con i rilievi con sensori termici e sensori RGB/NIR. Sono stati assegnati ai punti dei valori RGB, NDVI e di energia termica irradiata dalla superficie registrati dai rispettivi sensori ottici, NIR e dalla termocamera. L'assegnazione del valore è avvenuta tramite proiezione ortometrica dei punti sul piano immagine e assegnazione dei valori del pixel al punto. In questo modo sono stati assegnati valori R, G, B (riflettanza alla lunghezza d'onda dei colori rosso, verde e blu), NDVI (indice vegetazionale normalizzato, solitamente usando i valori di riflettanza nel rosso e nell'infrarosso), e di calore (temperatura relativa della superficie irradiante).

Una seconda categoria di descrittori consiste nelle caratteristiche geometriche estratte per ogni punto dalla nuvola di punti. Queste vengono estratte mediante analisi dei vicini più prossimi, impostando un raggio che si considera rappresentativo delle forme geometriche dell'area (Pirotti and Tonion 2019; Bernsteiner et al. 2020). Un altro approccio consiste nell'impostare un raggio massimo e di identificare il raggio ideale in modo iterativo mediante (M. Weinmann, Jutzi, and Mallet 2014; Martin Weinmann et al. 2015)

Una terza categoria di descrittori consiste nei rapporti nello spazio con l'infrastruttura oggetto di analisi. Questo gruppo di descrittori è utile per definire poi il grado di rischio determinato dalla vicinanza relativa.

Sono dunque stati associati ai punti le seguenti informazioni utili per il successivo “training”, i.e. addestramento, dell'algoritmo per la creazione del modello:

- valore di temperatura, ottenuto dall'immagine termica a 10 cm di GSD
- valore di indice NDVI ottenuto dall'immagine NDVI a 10 cm di GSD.
- valore di colore come individuato dall'ortofoto da drone, dunque con i tre valori della riflettanza nei colori fondamentali RGB.
- caratteristiche geometriche - queste metriche descrivono la forma degli oggetti nello spazio intorno ad ogni punto - vedi capitolo “Caratteristiche geometriche 3D” dedicato.
- distanza planimetrica dall'infrastruttura
- differenza di quota rispetto all'infrastruttura
- distanza 3d dall'infrastruttura
- pendenza verso l'infrastruttura (da verificare; in caso di terreni con morfologia complessa va utilizzato un approccio di “raytracing”)

4.2.2.2 Caratteristiche geometriche 3D Questa fase è quella più lunga dal punto di vista computazionale, in quanto per ogni punto deve trovare un insieme di punti vicini e calcolare diverse funzioni che forniscono indici di forma geometrica. In ambiente R una funzione applicata a 800k punti con un intorno di 10 punti circa a testa in un PC con 2.2 MHz ci mette 11 minuti se si utilizza la funzione “apply” ottimizzata a 2 minuti se si utilizza “vapply” o altre strategie di vettorializzazione della procedura. Un migliore approccio può essere quello di usare funzioni chiamate in ambiente C/C++, oppure passando il tutto ad un software esterno come CloudCompare. Questo però complicherebbe i passaggi. Per questo lavoro è stato dunque sviluppato una libreria R dedicata, CloudGeometry, disponibile nella repository GitHub <https://github.com/fpirotti/CloudGeometry>. Infatti l'ambiente R richiede che i moduli sviluppati nel suo ambiente mantengano una licenza aperta, ed è dunque stata messa a disposizione della comunità, e viene in questo contesto utilizzata per il futuro sviluppo della pipeline.

Nella figura sotto vengono riassunti alcuni degli indici di forma geometrica calcolati dal CloudGeometry. CloudGeometry inoltre sfrutta eventuali processori/core multipli delle macchine, parallelizzando il calcolo e dunque rendendo più veloce ed efficiente il processo. Si rimanda alla documentazione specifica nella repository della libreria per maggiori dettagli.




Fig. 4: Valori di Eigen della matrice di covarianza delle coordinate prese in un raggio idoneo (fonte immagine: Hansen et al. (2021) e Qin et al. (2018)).


5 Risultati

Sono stati applicati diversi metodi di machine learning e deep learning usando un cluster con 16 cores.

Si nota che il metodo Random Forest è 20x più veloce del metodo di deep learning classico con un singolo layer intermedio. L'implementazione della rete neurale artificiale è di tipo “feedforward” a più livelli addestrata tramite gradiente stocastico usando “backpropagation” e con le seguenti impostazioni:

- adaptive learning rate attiva
- numero di epoche = 10
- loss function = cross_entropy per il nostro caso (classificazione)

Considerando i vantaggi verranno utilizzate entrambe con tecniche di ensemble machine learning che combinano i risultati di diversi modelli di apprendimento per migliorare le prestazioni predittive.



6 Schemi progettuali dell'applicativo software

6.1 Premessa

La procedura per elaborare i vari passaggi deve necessariamente essere inserita in un applicativo interattivo che consente di applicare il processo a dati forniti dall'utente.

I dati saranno nuvole di punti e immagini con informazioni termiche e/o multispettrali, da drone e/o da aeromobili e/o satelliti.

L'applicativo consentirà di caricare file di progetto in un ambiente condiviso e di applicare i vari passaggi verificandone il buon funzionamento.

La procedura dovrà poi eseguire una pre-elaborazione per normalizzare i dati e indicizzarne i contenuti. Dopo le opportune verifiche di qualità dei dati, ovvero la densità dei punti del dato da LiDAR, la

risoluzione dei raster, e la loro necessaria sovrapposizione nell'area di studio, verrà applicato il modello di deep learning ai dati, producendo il prodotto finale.

Il risultato sarà un raster con valori numerici di pericolo nella scala che verrà ritenuta più opportuna. Il valore di rischio sarà mappato anche sulla nuvola di punti.

L'utente, se necessario, potrà scaricare il dato raster in formato GeoTIFF e la nuvola di punti in formato LAZ (LAS compresso).

Il sistema verrà implementato in un ambiente installabile su sistemi UNIX o Windows, con un'interfaccia accessibile dai normali browser di rete (Chromium, Firefox, Edge etc. . .). Questo consente una semplicità di utilizzo ed un'accessibilità maggiore, sia da utente locale sia, eventualmente, da un utente remoto.

Lo schema tecnico delle funzionalità e delle specifiche dell'applicativo software di deep learning è generalizzato nelle figure seguenti.

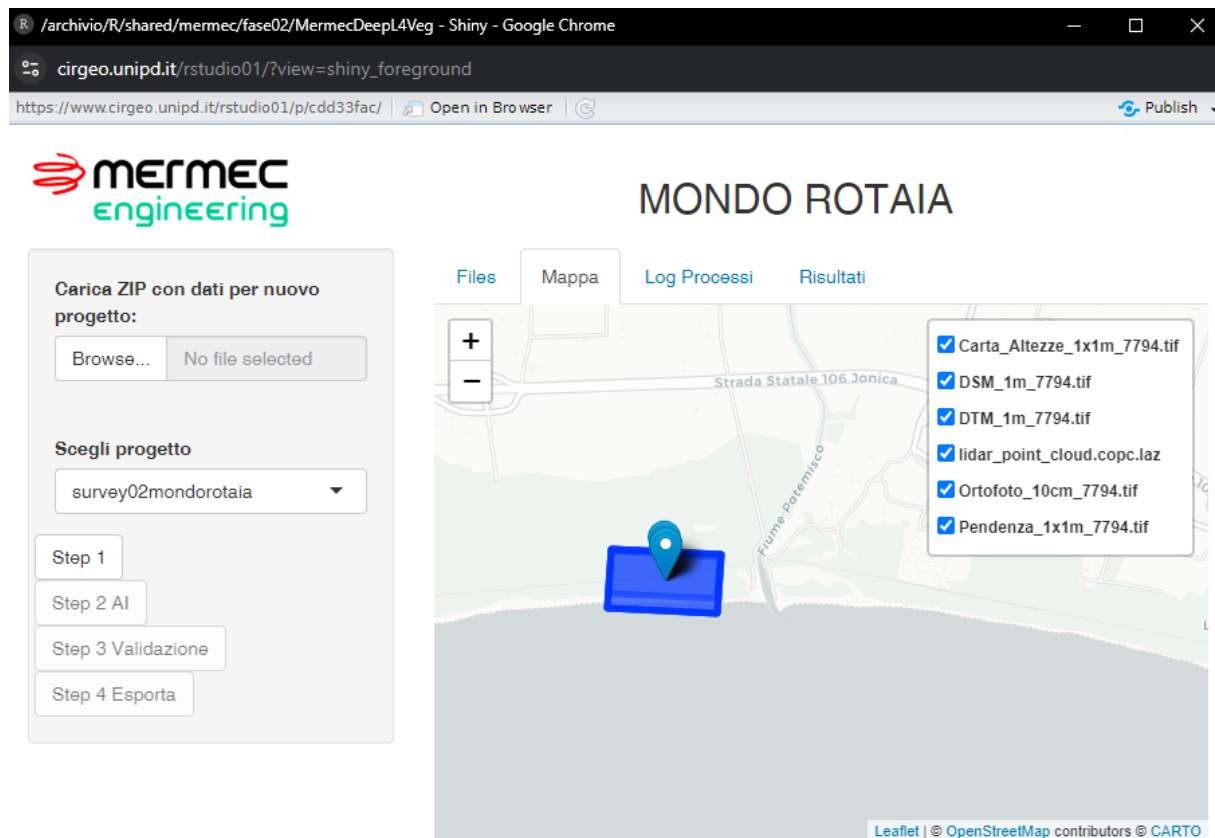
La pipeline di lavoro consisterà in moduli in ambiente R divisi per ogni fase di lavoro. Questi moduli verranno chiamati tramite una interfaccia grafica accessibile da browser, sfruttando l'infrastruttura messa a disposizione da diverse librerie R (e.g. Shiny). Questo sistema è ampiamente stato testato in diversi contesti, e consente di accedere al sistema anche da remoto. In altre parole è possibile centralizzare il calcolo in una macchina anche remota, dunque l'infrastruttura è scalabile da una workstation standard fino ad infrastrutture di HPC con diverse decine di processori.



Fig. 5: Componenti dello schema modulare di processo

6.2 Interfaccia

Nella figura sotto la possibile interfaccia per la gestione del processo.



6.3 Architettura

Considerando il tipo di output desiderato, verranno addestrati algoritmi diversi di machine learning per verificarne l'efficacia riguardo al problema specifico. Verrà utilizzata la combinazione ottimale, mediante approccio di Ensemble learning. L'architettura sarà l'implementazione di algoritmi "H2O Scalable Machine Learning Platform", su cluster JAVA interfacciata con R.

L'architettura dell'applicativo è basata su una piattaforma scalabile di machine learning (H2O) con un'interfaccia sviluppata in R, che permette l'elaborazione sia locale che remota. L'applicativo integra moduli per la pre-elaborazione dei dati, l'analisi tramite algoritmi AI, e la validazione dei risultati, accessibili tramite un'interfaccia web user-friendly.

6.4 Addestramento e validazione

L'addestramento verrà fatto sui dati condivisi. Considerando il grande numero di oggetti e descrittori (features) necessari per addestrare il modello in modo soddisfacente, verranno considerati anche dati aperti (con licenza CC o CC-BY o simili) disponibili in rete e simili allo scenario.

Per valutare le performance del modello verranno utilizzate le metriche di precisione, richiamo e F1-score. Verrà comunque analizzata la matrice di confusione per comprendere eventuali errori di mescolanza tra classi specifiche.

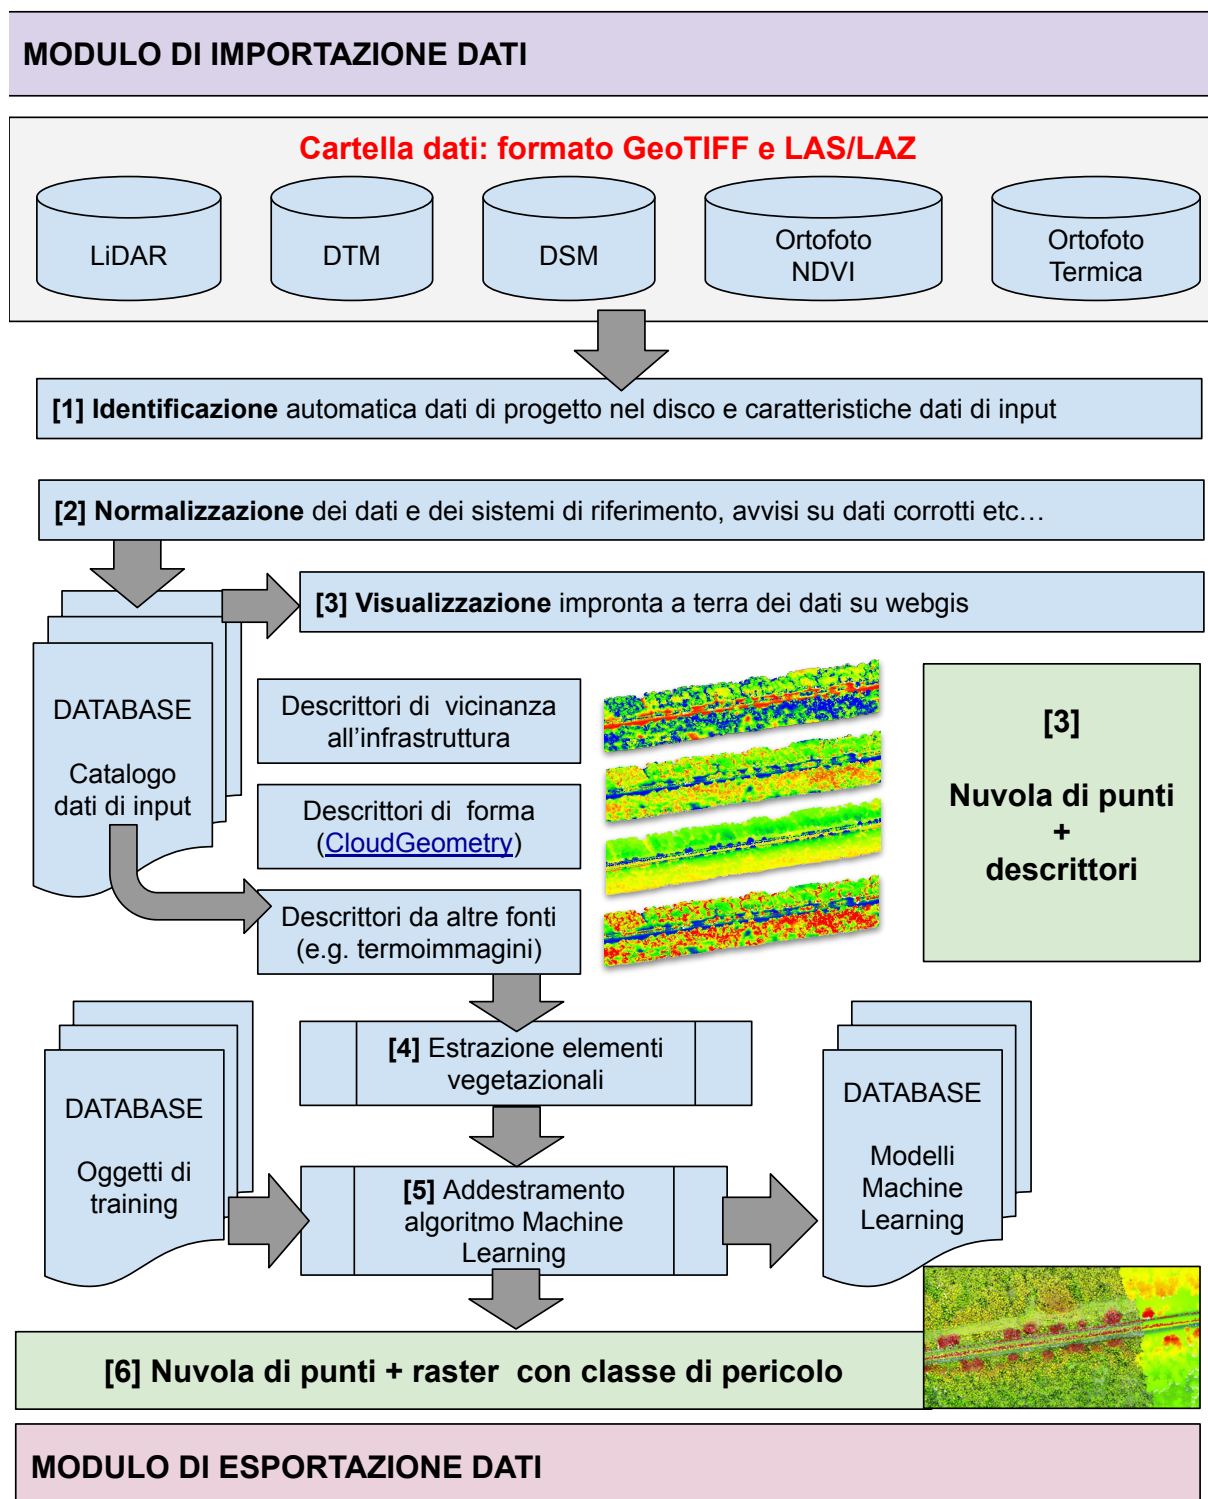


Fig. 6: Diagramma di flusso dell'applicativo software di deep learning integrato.

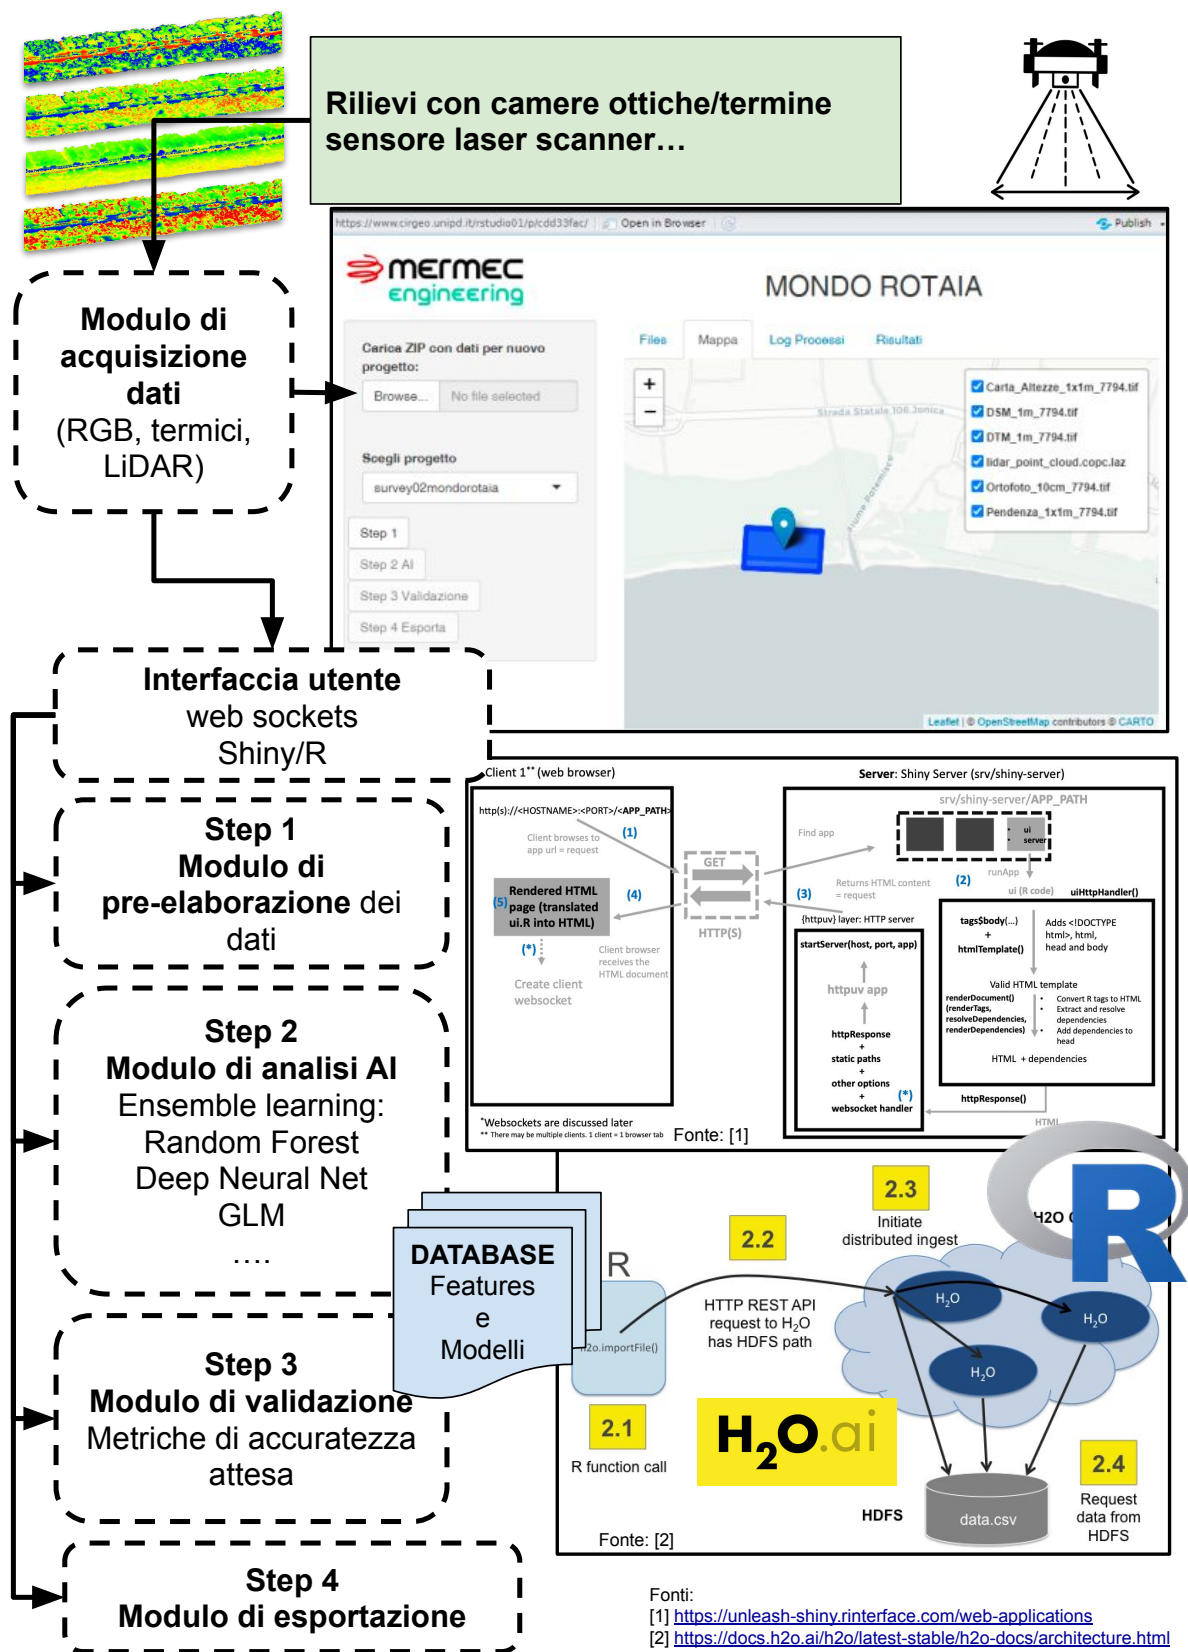


Fig. 7: Schema progettuale generale dell'applicativo software di deep learning integrato.

7 Proposte migliorative

Metodi di ottimizzazione sono necessari ed indubbiamente possibili. Indicizzazione degli elementi geospaziali e euristiche per isolare solamente i punti più critici ed applicare un'analisi più dettagliata. Sfruttare ove possibile il calcolo parallelo, dato che alcuni procedimenti possono essere sicuramente applicati in parallelo e dunque sfruttare infrastrutture con più processori al meglio.

Nella seconda fase verranno implementate dove possibile anche le proposte migliorative di cui sopra.

8 Riferimenti

- Bernsteiner, H, N Brožová, I Eischeid, A Hamer, S Haselberger, M Huber, A Kollert, T M Vandyk, and F Pirotti. 2020. "Machine Learning for Classification of an Eroding Scarp Surface Using Terrestrial Photogrammetry with NIR and RGB Imagery." *ISPRS Annals of Photogrammetry, Remote Sensing and Spatial Information Sciences* V-3-2020: 431437. <https://doi.org/10.5194/isprs-annals-V-3-2020-431-2020>.
- Chave, Jérôme, Maxime Réjou-Méchain, Alberto Búrquez, Emmanuel Chidumayo, Matthew S. Colgan, Wellington B. C. Delitti, Alvaro Duque, et al. 2014. "Improved Allometric Models to Estimate the Aboveground Biomass of Tropical Trees." *Global Change Biology* 20 (10): 3177–90. <https://doi.org/10.1111/gcb.12629>.
- Hansen, Signe Schilling, Verner Brandbyge Ernstsén, Mikkel Skovgaard Andersen, Zyad Al-Hamdani, Ramona Baran, Manfred Niedewieser, Frank Steinbacher, and Aart Kroon. 2021. "Classification of Boulders in Coastal Environments Using Random Forest Machine Learning on Topo-Bathymetric LiDAR Data." *Remote Sensing* 13 (20): 4101. <https://doi.org/10.3390/rs13204101>.
- MERMEC - Autori Vari. 2023. *PROGETTO DI RICERCA MONDOROTAIA - RELAZIONE TECNICA "INTERFERENZA DELLA VEGETAZIONE SULL'INFRASTRUTTURA FERROVIARIA"*. Photogrammetry & Remote Sensing, The American Society for. 2019. "Specification 1.4—R14." The American Society for Photogrammetry & Remote Sensing.
- Pirotti, F., and F. Tonion. 2019. "Classification of Aerial Laser Scanning Point Clouds Using Machine Learning: A Comparison Between Random Forest and Tensorflow." *ISPRS - International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences* XLII-2/W13: 11051111. <https://doi.org/10.5194/isprs-archives-XLII-2-W13-1105-2019>.
- Qi, Charles R, Li Yi, Hao Su, and Leonidas J Guibas. 2017. "PointNet++: Deep Hierarchical Feature Learning on Point Sets in a Metric Space." *arXiv Preprint arXiv:1706.02413*.
- Qin, Xinyan, Gongping Wu, Jin Lei, Fei Fan, Xuhui Ye, and Quanjie Mei. 2018. "A Novel Method of Autonomous Inspection for Transmission Line Based on Cable Inspection Robot LiDAR Data." *Sensors* 18 (2): 596. <https://doi.org/10.3390/s18020596>.
- Weinmann, Martin, Boris Jutzi, Stefan Hinz, and Clément Mallet. 2015. "Semantic Point Cloud Interpretation Based on Optimal Neighborhoods, Relevant Features and Efficient Classifiers." *ISPRS Journal of Photogrammetry and Remote Sensing* 105 (July): 286–304. <https://doi.org/10.1016/j.isprsjprs.2015.01.016>.
- Weinmann, M., B. Jutzi, and C. Mallet. 2014. "Semantic 3D Scene Interpretation: A Framework Combining Optimal Neighborhood Size Selection with Relevant Features." *ISPRS Annals of the Photogrammetry, Remote Sensing and Spatial Information Sciences* II-3 (August): 181–88. <https://doi.org/10.5194/isprsannals-II-3-181-2014>.